



Análisis multidimensional y predicción de accidentes cerebrovasculares

Proyecto de Aprendizaje de Máquina
Pipeline supervisado y no supervisado para ACV

Autor: Anthoni Hernandez

Código estudiantil 2191198 · UIS

1. Propósito del proyecto: pasar de datos clínicos a perfiles de riesgo

El objetivo fue construir un pipeline de Machine Learning capaz de clasificar riesgo de ACV y, además, perfilar grupos clínicos ocultos. El trabajo no se quedó en un solo modelo: comparó limpieza, escalado, modelos supervisados y aprendizaje no supervisado.

5.110

registros clínicos

11

variables originales

249

casos ACV

`pd.read_csv(sep=";")`

pipeline de ML


stroke objetivo




Idea central: el proyecto combina predicción del evento y descubrimiento de patrones clínicos accionables.

2. Dataset: variables que describen contexto, salud y estilo de vida

Tipo de trabajo (Drop)
Total: 4909 pacientes



Tipo de trabajo (Impute)
Total: 5110 pacientes



Variables continuas

age, avg_glucose_level y bmi. Son el centro de la señal biométrica y por eso requieren escalado.

Variables categóricas

gender, ever_married, work_type, Residence_type y smoking_status se transformaron con codificación para que los modelos pudieran leerlas.

Variable objetivo

stroke es binaria: 1 indica evento de ACV, 0 indica paciente sin evento.

get_dummies()

Label binario: stroke

DataFrame: 5110 x 11

La estructura del dataset obliga a unir estadística descriptiva, preprocesamiento y validación de modelos.

3. Pipeline trabajado: limpieza, entrenamiento y perfilamiento

Carga

lectura con separador correcto

Limpieza

DropNA vs imputación

Escalado


StandardScaler para distancias

Supervisado

DT, RF, SVM, MLP

No supervisado

PCA, K-Means, DBSCAN



`train_test_split(stratify=y)`

`StandardScaler()`

`SVC()`

`PCA()`

`KMeans() / DBSCAN()`

El flujo completo evita depender de una métrica aislada y permite contrastar decisiones técnicas.

4. Desbalance severo: el problema real no es la exactitud, es el recall

4.861

pacientes sin ACV
95,13 %

249


pacientes con ACV
4,87 %

Un modelo que prediga “todos sanos” puede parecer bueno en accuracy, pero sería inútil clínicamente. Por eso se priorizó TPR/recall de la clase positiva.

Métrica	Rol
Accuracy	visión global
TPR / Recall	detecta ACV
TNR	controla sanos

recall_score()

class_weight="balanced"



Para datos médicos desbalanceados, el recall positivo pesa más que una accuracy vistosa.

5. Calidad de datos: el BMI concentró el problema de valores faltantes

201

nulos en BMI


40

ACV dentro de esos nulos

16 %

pérdida de positivos si se borra

La columna bmi no podía tratarse como un detalle menor. Borrar filas eliminaba una fracción sensible de la clase más importante.

`df.isna().sum()``dropna()``bmi.fillna(median)`

Decisión clave: limpiar sin destruir información crítica de la clase minoritaria.

6. DropNA contra imputación: dos rutas para medir el sesgo

Caso 1: DropNA

Se eliminaron todas las filas con BMI faltante. El dataset bajó a 4.909 registros y los casos positivos quedaron en 209.

4.909

registros DropNA

5.110

registros imputados

Caso 2: Imputado

Se conservó la totalidad de registros. El dataset mantuvo 5.110 pacientes y los 249 casos positivos.

+40

positivos recuperados

La comparación se mantuvo durante todo el proyecto para revisar si la imputación deformaba la topología de los datos.

La imputación ganó sentido porque rescató evidencia clínica sin romper la estructura general del dataset.

7. Codificación y partición: preparar datos sin perder proporción de ACV

Codificación

Las variables categóricas se convirtieron a columnas binarias para que Decision Tree, Random Forest, SVM y PCA pudieran procesarlas.

Partición estratificada

Se usó estratificación para que train y test conservaran una proporción similar de pacientes con ACV.

3.927

Train DropNA

982

Test DropNA


4.088

Train imputado

`pd.get_dummies()``train_test_split(stratify=y)`

La preparación técnica fue tan importante como el modelo: sin estratificación, el recall queda contaminado.

8. Lectura demográfica: residencia, género y trabajo equilibran el contexto



Variable	Distribución
Género	2.994 mujeres / 2.115 hombres
Residencia	2.596 urbana / 2.514 rural
Trabajo	2.925 sector privado

La muestra es amplia y contiene perfiles de empleo, residencia y estado civil. Estos atributos no reemplazan a las variables clínicas, pero ayudan a contextualizar el riesgo.

value_counts()

crosstab()

La demografía aporta contexto, pero no debe sobredimensionarse frente a edad, glucosa y condiciones cardiovasculares.

9. Edad y glucosa: las variables clínicas con señal más clara


42,0edad media sin ACV
años**67,7**edad media con ACV
años**132,5**glucosa media con ACV
mg/dL

La edad separa mejor que casi cualquier otra variable, pero la frontera no es limpia: existen pacientes sanos y pacientes con ACV en rangos compartidos.

```
groupby("stroke").mean()
```


```
avg_glucose_level
```

```
age
```



La señal existe, pero la superposición biológica impide resolver el problema con reglas lineales simples.

10. Tabaquismo: variable de estilo de vida con lectura bivariada



Qué se contrastó

Se cruzó smoking_status contra stroke para observar porcentajes de ACV dentro de cada categoría.

Qué se observa

El historial de fumador permite perfilar riesgo, pero no separa por sí solo la clase positiva.


Función usada

`pd.crosstab(..., normalize="index")` permite comparar porcentajes y no solo conteos absolutos.

```
pd.crosstab()
```

El tabaquismo aporta una capa explicativa, pero el riesgo clínico sigue siendo multivariable.

11. Correlaciones: mapa rápido de la señal, no diagnóstico final



El heatmap ayudó a detectar qué columnas se relacionan más con stroke después de codificar las variables categóricas. Edad, glucosa y condiciones clínicas aparecen como señales más fuertes.

Hallazgo	Interpretación
Edad	principal señal positiva
Glucosa	riesgo metabólico
BMI	señal con outliers

df.corr()

Pearson

stroke

La correlación orienta el análisis, pero la decisión de modelo se tomó con validación y métricas clínicas.

12. Outliers y escalado: por qué la normalización era obligatoria

BMI con valores extremos

El rango de BMI va de 10,3 a 97,6. La media puede distorsionarse y por eso la mediana fue una decisión prudente para imputar.


Modelos sensibles a escala

SVM, PCA, K-Means y DBSCAN dependen de distancias. Sin escalado, glucosa dominaría el espacio geométrico.

`StandardScaler()`



`median()`

`IQR`




Sin escalado, el modelo aprende unidades de medida, no relaciones clínicas.

13. StandardScaler contra MinMaxScaler: la escala cambia la geometría

`MinMaxScaler()``StandardScaler()`
$$z = (x - \text{media}) / \text{desviación}$$

La elección final favoreció StandardScaler porque preservó mejor la morfología frente a outliers de glucosa.

14. Modelado supervisado: comparar modelos antes de decidir



Criterio real de selección

No se escogió el modelo solo por accuracy. En un problema de ACV, fallar positivos es más grave que alertar de más.

Modelos evaluados



DecisionTreeClassifier,
RandomForestClassifier, SVC y
MLPClassifier.

`accuracy_score()`

`recall_score()`

La comparación final obliga a mirar desempeño global y sensibilidad clínica al mismo tiempo.

15. Árbol de decisión: profundidad baja detecta, profundidad alta sobreajusta





DecisionTreeClassifier()

max_depth=1

max_depth=4

El árbol nivel 4 equilibró mejor recall y especificidad que un árbol demasiado simple o totalmente libre.

16. Random Forest: muchos árboles reducen inestabilidad, pero no eliminan el desbalance

`RandomForestClassifier()``n_estimators``class_weight="balanced"`

El bosque suaviza decisiones individuales, pero el recall positivo sigue dependiendo del manejo de clases.

17. SVM: el margen máximo se probó con kernels lineal, polinomial y RBF


Kernel	Accuracy	TPR ACV	Lectura
Lineal DropNA	0,748	0,802	recall alto
RBF imputado	0,746	0,696	más estable
Poly DropNA	0,820	0,556	accuracy engañosa

SVM busca una frontera de separación. En datos clínicos solapados, los kernels permiten revisar si una frontera curva captura mejor el riesgo.

SVC(kernel="linear")



SVC(kernel="rbf")

StratifiedKfold




La métrica clínica permitió detectar cuándo una accuracy superior escondía peor sensibilidad.

18. Validación cruzada: KFold fallaba cuando los positivos quedaban mal repartidos

`KFold()``StratifiedKFold()``cross_val_score()`

Estratificar no es un lujo: en clase minoritaria evita particiones sin suficientes casos positivos.

19. Matriz de confusión: ver el error donde más duele



Lectura clínica

Los falsos negativos son el error más delicado porque representan pacientes con ACV que el modelo no detecta.

Lectura operativa

Los falsos positivos generan alertas adicionales, pero son menos críticos que dejar pasar un caso real.



Función usada

`confusion_matrix()` resume el resultado entre predicción y etiqueta real.

`confusion_matrix()`


La matriz traduce números a decisiones: detectar más ACV fue la prioridad técnica.

20. Red neuronal MLP: alta accuracy, baja sensibilidad para ACV

`MLPClassifier()``hidden_layer_sizes``max_iter / epochs`

En este dataset tabular y desbalanceado, más capas no significaron mejor detección de pacientes con ACV.

21. PCA: la visualización confirma la mezcla de sanos y pacientes con ACV

**52,3 %**

varianza DropNA

52,2 %

varianza imputado

PCA reduce el espacio a dos componentes para observar forma y solapamiento. La mezcla de colores muestra que no hay una frontera lineal limpia.


PCA(n_components=2)

explained_variance_ratio_

La reducción dimensional justificó buscar modelos no lineales y clusters de perfilamiento, no diagnóstico directo.

22. K-Means con K=2: forzar “sano/enfermo” no respeta la biología

K-Means (K=2) proyectado con PCA
CASO 1 (DROPNA)




KMeans(n_clusters=2)

fit_predict()


PCA para graficar

K-Means (K=2) proyectado con PCA
CASO 2 (IMPUTADO)



K=2 agrupó patrones generales de pacientes, pero no separó diagnóstico de ACV.

23. Fenotipos clínicos: K=4 permite perfiles accionables



Fenotipo	Perfil aproximado	Riesgo
1	Edad 60 / Glucosa 207	12,5 %
2	Edad 56 / Glucosa 90	5,7 %
0	Edad 41 / Glucosa 89	1,5 %
3	Edad 14 / Glucosa 93	0,2 %


K-Means no se usó como diagnóstico individual, sino como estratificador de población: bajo, moderado, alto y crítico.

KMeans(n_clusters=4)

cluster_centers_

La decisión fuerte fue no confundir clustering con diagnóstico: K=4 sirve para priorización poblacional.

24. Método del codo: escoger K con matemática, no por intuición



Lectura de la inercia

La inercia siempre baja al aumentar K. El codo busca el punto donde añadir clusters deja de aportar una mejora fuerte.

Decisión


K=4 queda como equilibrio práctico: suficiente segmentación clínica sin convertir el resultado en 15 grupos difíciles de explicar.

`inertia_``range(1, 15)``K=4`

El codo defendió la elección de K=4 como interpretación útil, no como adivinanza visual.

25. DBSCAN: densidad, vecindarios y puntos atípicos clínicos


Paso 1: Método del Codo (K-Distancias) - Definiendo la Zona Óptima en Bloque 1 (DropNa)



NearestNeighbors(n_neighbors=10)

DBSCAN(eps, min_samples)

Paso 1: Método del Codo (K-Distancias) - CASO 2 (Imputado)




eps≈1,7 / 1,75


El gráfico de k-distancias delimitó la zona de transición antes de fijar eps.

26. Sensibilidad topológica: extremos de eps muestran por qué calibrar importa

Paso 2: Comportamiento MACRO de DBSCAN



Paso 3: Análisis MICRO de DBSCAN (Fine-Tuning en la Frontera)



eps=0,5: demasiado estricto


eps=5,0: demasiado laxo

min_samples=10


DBSCAN funciona como filtro de anomalías solo cuando eps se calibra en la frontera de densidad.

27. Resultado no supervisado final: perfilamiento estable entre DropNA e imputado

Resumen de Aprendizaje No Supervisado - CASO 1 (DropNA)



Resumen de Aprendizaje No Supervisado - CASO 2 (Imputado)



KMeans + DBSCAN + PCA

ruido clínico $\approx 0,2\%$

topología estable

La imputación conservó la forma general de los datos y permitió no perder pacientes críticos.

Conclusiones del proyecto

1. El problema es multidimensional

La clase ACV se superpone con pacientes sanos. Por eso no basta una regla lineal ni una sola variable.

2. La imputación fue la decisión correcta

Eliminar BMI faltante borraba 40 casos positivos. Imputar conservó la señal y no deformó fuertemente la topología.

3. K-Means sirve para perfilar, no para diagnosticar

El valor real de $K=4$ fue construir fenotipos de riesgo: bajo, moderado, alto y crítico.

4. DBSCAN aporta vigilancia de anomalías

La calibración de ϵ permitió ubicar pacientes atípicos que merecen revisión personalizada.

Mi conclusión personal: el curso dejó claro que un modelo no vale por verse complejo, sino por responder bien al problema real. En salud, el objetivo no es lucir accuracy, sino reducir omisiones peligrosas y explicar las decisiones con datos.

Funciones y herramientas que sostienen el análisis

pandas

```
pd.read_csv()  
get_dummies()  
crosstab()
```

scikit-learn

```
StandardScaler()  
train_test_split()  
StratifiedKFold()
```

modelos supervisados

```
DecisionTreeClassifier()  
RandomForestClassifier()  
SVC()  
MLPClassifier()
```

no supervisado

```
PCA()  
KMeans()  
DBSCAN()  
NearestNeighbors()
```

Estas funciones no se presentaron como piezas del pipeline que justifican cada decisión técnica.